

# Contents

<b>1</b>	<b>Procesos estocásticos y datos de series temporales</b>	<b>2</b>
1.1	Datos de series temporales vs datos de sección cruzada . . . . .	3
1.2	El desafío . . . . .	3
<b>2</b>	<b>Estacionariedad</b>	<b>3</b>
2.1	Estacionariedad en sentido débil . . . . .	4
2.2	Función de autocovarianzas y función de autocorrelación . . . . .	4
<b>3</b>	<b>Transformaciones de realizaciones de procesos estocásticos NO estacionarios</b>	<b>5</b>
3.1	Internat. airline passengers: monthly totals in thousands. Jan 49 – Dec 60 . . . . .	5
3.1.1	Trasformación logarítmica de los datos . . . . .	6
3.1.2	Primera diferencia del logaritmo de los datos . . . . .	8
3.1.3	Diferencia estacional de la primera diferencia del logaritmo de los datos . . .	8
3.2	Tasa logarítmica de crecimiento . . . . .	9
3.2.1	Observaciones sobre los datos transformados . . . . .	10

# Econometría Aplicada. Lección 1

Marcos Bujosa

June 18, 2024

## Carga de algunos módulos de python

---

```
1 # Para trabajar con los datos y dibujarlos necesitamos cargar algunos módulos de python
2 import numpy as np # linear algebra
3 import pandas as pd # data processing, CSV file I/O (e.g. pd.read_csv)
4 import matplotlib as mpl
5 import matplotlib.pyplot as plt # data visualization
6 mpl.rc('text', usetex=True)
7 mpl.rc('text.latex', preamble=r'\usepackage{amsmath}')
8 import dataframe_image as dfi
```

---

```
1 from sympy.printing.preview import preview
2
3 def repr_png(tex, ImgFile):
4     preamble = "\\documentclass[preview]{standalone}\\n" \
5         "\\usepackage{booktabs,amsmath,amsfonts}\\begin{document}"
6     preview(tex, filename=ImgFile, viewer='file', preamble=preamble, dvioptions=['-D','250'])
7     #return open(ImgFile, 'rb').read()
```

---

## 1 Procesos estocásticos y datos de series temporales

**Proceso estocástico** es una secuencia de variables aleatorias  $X_t$

$$\mathbf{X} = \{X_t \mid t = 0, \pm 1, \pm 2, \dots\};$$

donde el conjunto de índices  $t$  recorre el conjunto de números enteros ( $\mathbb{Z}$ ).

**Serie temporal** es una secuencia de datos tomados a lo largo del tiempo

$$\mathbf{x} = (x_1, x_2, \dots, x_n)$$

- Consideraremos cada dato  $x_t$  como una *realización de una variable aleatoria*  $X_t$ .
- Consecuentemente, consideraremos que una *serie temporal* es una *realización de un tramo* de un proceso estocástico:

$$(x_1, x_2, \dots, x_n) \text{ es una realización de } \{X_t \mid t = 1, 2, \dots, n\}.$$

## 1.1 Datos de series temporales vs datos de sección cruzada

**Series temporales** Corresponden a mediciones de un mismo objeto a lo largo del tiempo. El índice indica el instante de cada medición. Consecuentemente, el orden temporal de los datos podría ser fundamental para explicar cada uno de ellos.

- El motivo es que frecuentemente la medición en un instante de tiempo está relacionada con otras mediciones próximas en el tiempo.
- Esto presupone que en el proceso estocástico subyacente,  $\mathbf{X} = \{X_t\}$ , las variables aleatorias no son independientes entre sí.

**Sección cruzada** el índice NO es cronológico. Cada índice es solo una *etiqueta* (asignada arbitrariamente) que identifica al individuo, empresa, objeto, etc. que ha sido medido.

- Por tanto, *el orden en el que aparecen los datos es irrelevante*.
- Consecuentemente, conocer únicamente el índice de un dato no permite deducir nada respecto de cualquier otro dato.

## 1.2 El desafío

El análisis de *series temporales* trata sobre la inferencia estadística de muestras que **frecuentemente NO podemos asumir que sean realizaciones** de variables aleatorias *i.i.d.* (*independientes e idénticamente distribuidas*).

Además,

- Aunque el marco ideal es que la serie temporal analizada "**sea estacionaria**" (*abuso del lenguaje que expresa que podemos asumir que la serie es una realización de un proceso estocástico estacionario*)
- lo habitual es que, por distintos motivos, **NO lo sea**

El desafío para el analista es

**primero** transformar los datos para lograr que sean "**estacionarios**"

**y después** transformar los datos estacionarios en una secuencia de "**datos i.i.d**"

(*nuevo abuso del lenguaje que expresa que podemos asumir que los datos son realizaciones de variables aleatorias i.i.d.*)

## 2 Estacionariedad

El mayor objetivo del *análisis de series temporales* es inferir la distribución de un proceso  $\mathbf{X} = \{X_t\}$  usando una muestra (serie temporal)  $\mathbf{x} = (x_1, x_2, \dots, x_n)$ . Así podremos

**Predecir** datos futuros

**Controlar** datos futuros

Pero esto es casi imposible si los datos son inestables o caóticos a lo largo del tiempo

Por tanto, algún tipo de estabilidad o estacionariedad es necesaria.

## 2.1 Estacionariedad en sentido débil

Un proceso estocástico  $\mathbf{X} = \{X_t\}$  se dice **estacionario** (*en sentido débil*) si para todo  $t$  y  $k$  de  $\mathbb{Z}$

$$E(X_t) = \mu \quad (1)$$

$$Cov(X_t, X_{t-k}) = \gamma_k \quad (2)$$

- La primera igualdad sugiere que las realizaciones de  $\{X_t\}$  generalmente oscilan entorno a  $\mu$ .
- La segunda sugiere que la variabilidad de las realizaciones de  $\{X_t\}$  entorno a  $\mu$  es constante, pues para el caso particular  $k = 0$

$$Cov(X_t, X_{t-0}) = Var(X_t) = \gamma_0 \quad \text{para todo } t$$

Es decir,  $\gamma_0$  es la varianza común a todas las variables aleatorias del proceso.

## 2.2 Función de autocovarianzas y función de autocorrelación

- La secuencia  $\{\gamma_k\}$  con  $k \in \mathbb{Z}$  se denomina *función de autocovarianzas*
- La secuencia  $\{\rho_k\}$  con  $k \in \mathbb{Z}$ , donde

$$\rho_k = \frac{Cov(X_t, X_{t-k})}{\sqrt{Var(X_t)Var(X_{t-k})}} = \frac{\gamma_k}{\gamma_0}$$

se denomina *función de autocorrelación* (ACF).

Debido a la estacionariedad, la correlación entre  $X_t$  y  $X_{t+k}$  no depende de  $t$ ; tan solo depende de la distancia temporal  $k$  entre ambas variables.

Es más, la desigualdad de Chebyshev


$$P(|X_t - \mu| \geq c\sigma) \leq \frac{1}{c^2}, \quad \text{donde } \sigma = \sqrt{\gamma_0}$$

sugiere que para cualquier proceso estacionario (y un  $c$  grande), al pintar una realización, tan solo un pequeño porcentaje de los datos caerán fuera de la franja  $(\mu - c\sigma, \mu + c\sigma)$ .

---

```
1 import statsmodels.api as sm
2 np.random.seed(12345)
3 arparams = np.array([.75, -.25])
4 maparams = np.array([.65, .35])
5 ar = np.r_[1, -arparams] # add zero-lag and negate
6 ma = np.r_[1, maparams] # add zero-lag
7 y = sm.tsa.arma_generate_sample(ar, ma, 250)
8 plt.figure(figsize=(15,5))
9 plt.plot(y)
10 plt.savefig(image) # "image" no definido. Comentar esta línea al ejecutar el notebook
```

---



### 3 Transformaciones de realizaciones de procesos estocásticos NO estacionarios

Un proceso estocástico  $\mathbf{X} = \{X_t\}$  puede ser

**NO estacionario en media** porque  $E(X_t)$  depende de  $t$ .

**NO estacionario en covarianza** porque  $Cov(X_t, X_{t-k})$  depende de  $t$ .

Separar o distinguir ambos tipos de no estacionariedad no es sencillo.

Veamos ejemplos de series temporales para los que

- no podemos asumir que son realizaciones de procesos estocásticos estacionarios
- y algunos intentos de transformación para obtener datos "**estacionarios**" (\*)  
(recuerde que esta expresión, aunque extendida, es un abuso del lenguaje).

#### 3.1 Internat. airline passengers: monthly totals in thousands. Jan 49 – Dec 60

Leemos los datos de un fichero csv y generamos un dataframe de pandas.

---

```

1 OrigData = pd.read_csv('./database/Datasets-master/airline-passengers.csv')
2 OrigData['Month']=pd.to_datetime(OrigData['Month'])
3 OrigData=OrigData.set_index(['Month'])
4 print(OrigData.head())

```

---

$$\mathbf{x} = (x_1, \dots, x_{114})$$


---

```

1 plt.figure(figsize=(15,5))
2 plt.subplot(1, 2, 1)
3 plt.plot(OrigData['Passengers'])
4 plt.xlabel("Month")
5 plt.ylabel(r"Number of Air Passengers, ( $\mathbf{x}$ )")
6 plt.subplot(1, 2, 2)
7 plt.hist(OrigData['Passengers'], edgecolor='white', bins=11)
8 plt.tight_layout()
9 plt.savefig(image) # "image" no definido. Comentar esta línea al ejecutar el notebook

```

---



Serie "no estacionaria" (\*):

- La media crece de año en año
- La variabilidad estacional crece de año en año (fíjese en la diferencia entre el verano y el otoño de cada año)

### 3.1.1 Transformación logarítmica de los datos

- Al aplicar la función logarítmica transformamos **monótonamente** los datos estabilizando la varianza cuando los valores son mayores que 0.567 (aprox.)
- ¡Pero ocurre lo contrario, pues se amplifica el valor absoluto, cuando los valores están entre 0 y 0.567! De hecho,  $\lim_{x \rightarrow \infty} \ln(x) = -\infty$
- Además, *el logaritmo no está definido para valores negativos.*


---

```

1  # Definir el rango de valores para x (empezando desde un número positivo ya que log(0) no está definido)
2  x = np.linspace(0.01, 7, 400) # Valores de 0.1 a 10
3
4  # Calcular y = log(x)
5  y = np.log(x)
6
7  # Crear el gráfico
8  plt.figure(figsize=(16, 5))
9  plt.plot(x, y, label='y = ln(x)')
10
11 # Añadir etiquetas y título
12 plt.xlabel('x')
13 plt.ylabel('ln(x)')
14 plt.title('Gráfico de la función logarítmica y = ln(x)')
15 plt.axhline(0, color='black',linewidth=0.5)
16 plt.axvline(0, color='black',linewidth=0.5)
17 plt.grid(color = 'gray', linestyle = '--', linewidth = 0.5)
18 plt.legend()
19
20 plt.savefig(image) # "image" no definido. Comentar esta línea al ejecutar el notebook

```

---



$$\ln \mathbf{x} = (\ln(x_1), \dots, \ln(x_{114}))$$

Vamos a crear un nuevo `dataframe` con los datos originales y varias transformaciones de los datos

---

```

1 TransformedData = OrigData.copy()
2 TransformedData['dataLog'] = np.log(OrigData['Passengers'])
3 TransformedData['dataLogDiff'] = TransformedData['dataLog'].diff(1)
4 TransformedData['dataLogDiffDiff12'] = TransformedData['dataLogDiff'].diff(12)

```

---



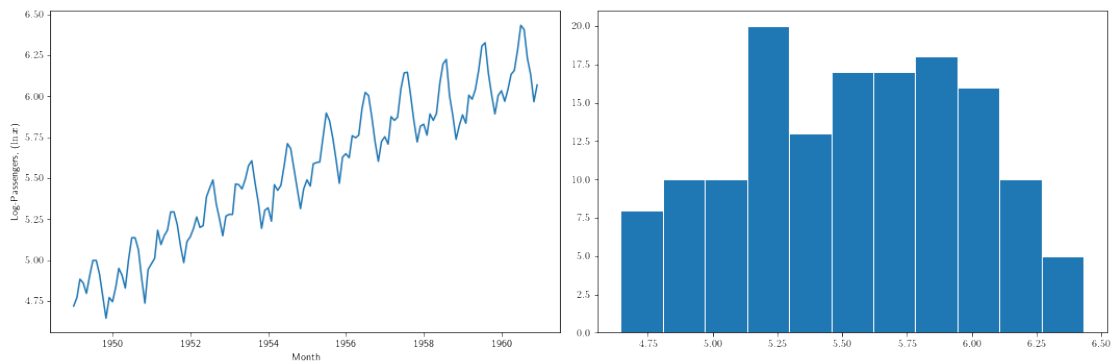
---

```

1 plt.figure(figsize=(15,5))
2 plt.subplot(1, 2, 1)
3 plt.plot(TransformedData['dataLog'])
4 plt.xlabel("Month")
5 plt.ylabel(r"Log-Passengers, ( $\ln \mathbf{x}$ ) ")
6 plt.subplot(1, 2, 2)
7 plt.hist(TransformedData['dataLog'], edgecolor='white', bins=11)
8 plt.tight_layout()
9 plt.savefig(image) # "image" no definido. Comentar esta línea al ejecutar el notebook

```

---



Ésta tampoco parece la realización de un proceso estocástico *estacionario*

- Ahora la variabilidad estacional parece mantenerse de año en año
- Pero la media sigue creciendo de año en año

### 3.1.2 Primera diferencia del logaritmo de los datos

$$\mathbf{y} = \nabla \ln \mathbf{x} = \left( [\ln(x_2) - \ln(x_1)], \dots, [\ln(x_{114}) - \ln(x_{113})] \right)$$


---

```

1 plt.figure(figsize=(15,5))
2 plt.subplot(1, 2, 1)
3 plt.plot(TransformedData['dataLogDiff'])
4 plt.xlabel("Month")
5 plt.ylabel(r"$\nabla \ln \boldsymbol{x}$")
6 plt.subplot(1, 2, 2)
7 plt.hist(TransformedData['dataLogDiff'], edgecolor='white', bins=11)
8 plt.tight_layout()
9 plt.savefig(image) # "image" no definido. Comentar esta línea al ejecutar el notebook

```

---



Esta serie tampoco parece "estacionaria" (\*)

- Hay un componente periódico (de naturaleza estacional), debido a que hay pocos viajes en otoño y muchos en Navidad, Semana Santa y verano (i.e., el número esperado de viajeros parece cambiar en función del mes o estación del año).

### 3.1.3 Diferencia estacional de la primera diferencia del logaritmo de los datos

$$\mathbf{z} = \nabla_{12}(\nabla \ln \mathbf{x}) = \nabla_{12}(\mathbf{y}) = \left( (y_{13} - y_1), \dots, (y_{113} - y_{101}) \right)$$

---


```

1 plt.figure(figsize=(15,5))
2 plt.subplot(1, 2, 1)
3 plt.plot(TransformedData['dataLogDiffDiff12'])
4 plt.xlabel("Month")
5 plt.ylabel(r"$\nabla_{12} \nabla \ln \boldsymbol{x}$")
6 plt.subplot(1, 2, 2)
7 plt.hist(TransformedData['dataLogDiffDiff12'], edgecolor='white', bins=11)
8 plt.tight_layout()
9 plt.savefig(image) # "image" no definido. Comentar esta línea al ejecutar el notebook

```

---





Esta serie se aproxima más al aspecto de la realización de un proceso *estacionario*

- Aunque parece haber más varianza a principios de los 50 que a finales
- De propina, el histograma sugiere una distribución aproximadamente Gaussiana

### 3.2 Tasa logarítmica de crecimiento

---

```

1  START = 100
2  UnoPorCiento = lambda n0, t: n0 if t<=1 else 1.01 * UnoPorCiento(n0, t-1)
3  TasaLogCrecimiento = pd.DataFrame({'$y_t$': [UnoPorCiento(START,t+1) for t in range(10)]})
4  TasaLogCrecimiento['$\frac{y_t - y_{t-1}}{y_{t-1}}$'] = TasaLogCrecimiento['$y_t$'].pct_change()
5  TasaLogCrecimiento['$\ln y_t$'] = np.log(TasaLogCrecimiento['$y_t$'])
6  TasaLogCrecimiento['$\nabla \ln y_t$'] = TasaLogCrecimiento['$\ln y_t$'] - TasaLogCrecimiento['$\ln y_{t-1}$'].shift(1)
7  TasaLogCrecimiento['$\frac{y_t - y_0}{y_0}$'] = TasaLogCrecimiento['$y_t$'].apply(lambda x: ((x/START)-1))
8  TasaLogCrecimiento['$\ln y_t - \ln y_0$'] = TasaLogCrecimiento['$\ln y_t$'] - TasaLogCrecimiento['$\ln y_0$'].iloc[0]

```

---

```

1  dfi.export(TasaLogCrecimiento, file, use_mathjax=True, dpi=200)

```

---

La tasa logarítmica de variación de  $y$  se define como  $z_t = \ln y_t - \ln y_{t-1}$ ; es decir

$$z = \nabla \ln y = \left( [\ln(y_2) - \ln(y_1)], \dots, [\ln(y_n) - \ln(y_{n-1})] \right)$$

y se *aproxima* a la tasa de crecimiento (en tanto por uno) si el incremento es pequeño.

	$y_t$	$\frac{y_t - y_{t-1}}{y_{t-1}}$	$\ln y_t$	$\nabla \ln y$	$\frac{y_t - y_0}{y_0}$	$\ln y_t - \ln y_0$
0	100.000000	NaN	4.605170	NaN	0.000000	0.000000
1	101.000000	0.01	4.615121	0.00995	0.010000	0.009950
2	102.010000	0.01	4.625071	0.00995	0.020100	0.019901
3	103.030100	0.01	4.635021	0.00995	0.030301	0.029851
4	104.060401	0.01	4.644972	0.00995	0.040604	0.039801
5	105.101005	0.01	4.654922	0.00995	0.051010	0.049752
6	106.152015	0.01	4.664872	0.00995	0.061520	0.059702
7	107.213535	0.01	4.674823	0.00995	0.072135	0.069652
8	108.285671	0.01	4.684773	0.00995	0.082857	0.079603
9	109.368527	0.01	4.694723	0.00995	0.093685	0.089553

### 3.2.1 Observaciones sobre los datos transformados

Transformación de la serie temporal $\mathbf{y} = \{y_t\}, t = 1 : n$	Observaciones
$\mathbf{z} = \ln \mathbf{y} = \{\ln y_t\}$	A veces independiza la volatilidad del nivel e induce normalidad.
$\mathbf{z} = \nabla \mathbf{y} = \{y_t - y_{t-1}\}$	Indica al crecimiento absoluto entre periodos consecutivos.
$\mathbf{z} = \nabla \ln \mathbf{y}$	Tasa logarítmica de crecimiento. Aproximación del crecimiento relativo entre periodos consecutivos.
$\mathbf{z} = \nabla \nabla \ln \mathbf{y} = \nabla^2 \ln \mathbf{y}$	Cambio en la tasa log, de crecimiento. Indica la “aceleración” en el crecimiento relativo.
$\mathbf{z} = \nabla_s \ln \mathbf{y} = \{\ln y_t - \ln y_{t-s}\}$	Tasa de crecimiento acumulada en un ciclo estacional completo ( $s$ periodos). Cuando el período estacional es de un año, se conoce como “tasa anual” o “tasa interanual”.
$\mathbf{z} = \nabla \nabla_s \ln \mathbf{y}$	Cambio en la tasa de crecimiento acumulada en un ciclo estacional completo. Es un indicador de aceleración en el crecimiento acumulado.